

MBA - Inteligência Artificial e Big Data

Aplicação de Redes Neurais Convolucionais na
Classificação de Imagens de Raio-X do Tórax para Auxílio
no Diagnóstico da COVID-19

Aluna: Flávia Guimarães Gaia Paula

flaviaggppaula@gmail.com

Orientador: Prof. Dr. Zhao Liang

Turma 1



Introdução



Desafio Global: A Emergência da COVID-19



COVID-19



Normal



Problema a ser Resolvido: Diagnóstico Preciso e Rápido da COVID-19

Neste trabalho, explorei a aplicação de Redes Neurais Convolucionais para enfrentar os desafios do diagnóstico da COVID-19.



Trabalhos relacionados

Tabela 1 – Comparação dos Trabalhos Correlatos

Trabalho	Metodologia	Dados	Objetivo
(RESHI <i>et al.</i> , 2021)	CNN profunda	Imagens de raio-x do tórax	Deteção de COVID-19
(OHATA <i>et al.</i> , 2020)	Transfer Learning	Imagens de raio-x do tórax	Deteção de COVID-19
(BARBOSA; COELHO; BAFFA, 2021)	CNN	Imagens de raio-x do tórax	Deteção de COVID-19
(CHRISTOFOLLETTI; ATTUX, 2022)	CNN	Imagens de raio-x do tórax	Deteção de COVID-19 e Pneumonia viral
(SILVA <i>et al.</i> , 2020)	InceptionResNetV2 e ResNetX50	Imagens de raio-x do tórax	Deteção de COVID-19 e Pneumonia viral

Aplicação das CNNs na análise e classificação de imagens médicas

- (RESHI *et al.*, 2021): Utiliza CNNs na classificação de imagens de raio-x do tórax relacionadas à COVID-19. A estratégia empregada, que utiliza uma CNN profunda, alcança uma precisão surpreendentemente próxima de 100%.
- (OHATA *et al.*, 2020): Experimenta com várias arquiteturas de CNNs que foram inicialmente treinadas com o conjunto de dados ImageNet. Utilizando técnicas de Transfer Learning, o estudo avalia a eficácia dessas redes em conjunto com algoritmos tradicionais, como k-Nearest Neighbor e SVM. As combinações mais eficientes alcançaram precisão e pontuação F1 superiores a 95%.
- (BARBOSA; COELHO; BAFFA, 2021): Otimiza uma CNN para reduzir o custo de processamento sem sacrificar a acurácia na detecção da COVID-19. A rede, que é relativamente simplificada com apenas três camadas convolucionais, demonstrou uma notável precisão de 99,36%.
- (CHRISTOFOLLETTI; ATTUX, 2022): As Dense Convolutional Networks foram utilizadas para identificar outras doenças com resultados encorajadores.
- (SILVA *et al.*, 2020): Adotou as arquiteturas InceptionResNetV2 e ResNetX50 para classificar imagens de raio-x. Dentre as arquiteturas testadas, a ResNetX50 mostrou-se superior conforme as métricas utilizadas.




Proposta: desenvolvimento do trabalho

Tabela 2 – Distribuição do número de imagens por classe em diferentes conjuntos de dados

Dataset	Classe	Nº de imagens extraídas da classe	Total de imagens
(KERMANY <i>et al.</i> , 2018)	Covid	504	504
	Normal	00	
(JAMDADE, 2020)	Covid	01	80
	Normal	79	
(COHEN <i>et al.</i> , 2020)	Covid	00	1502
	Normal	1502	

- Uma base de dados foi criada para este projeto, composta por imagens de raio-x classificadas em duas categorias: “Covid” e “Normal”. Essas imagens foram coletadas de vários conjuntos de dados.
- A base de dados, que foi filtrada para remover duplicatas, contém um total de 2.089 imagens. Dessas, 505 são diagnosticadas como COVID-19 (aproximadamente 24.18%) e 1.580 são classificadas como normais (aproximadamente 75.82%).

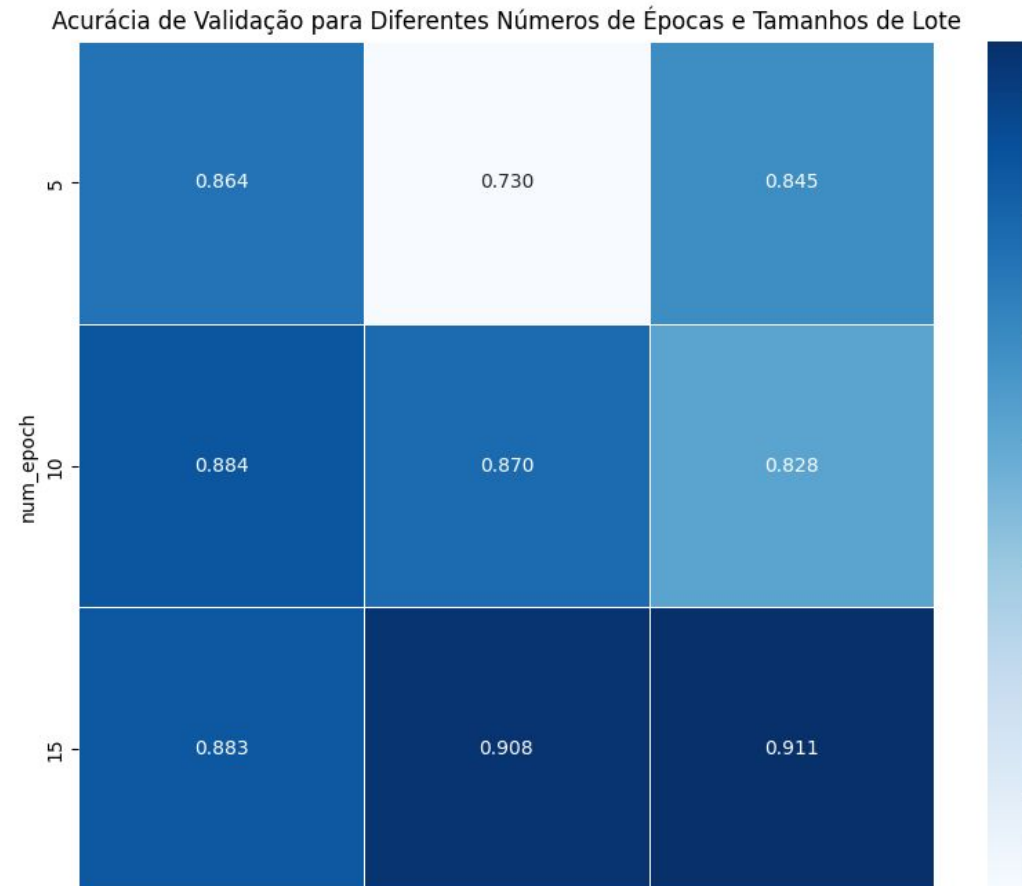
Figura 5 – Efeito das técnicas do ImageDataGenerator em uma imagem de raio-x.



- Aumento de dados com ImageDataGenerator: reescalonamento, zoom, range de cisalhamento e virar as imagens horizontalmente.
- Para o conjunto de teste, apenas o reescalonamento foi aplicado, pois, durante o teste, não queremos alterar ou aumentar os dados.
- Por fim as imagens foram redimensionadas para 64x64 pixels e foram organizadas em lotes de 16 imagens para otimizar o processo de treinamento.



Proposta: desenvolvimento do trabalho



A otimização de hiperparâmetros com o Grid Search foi essencial para escolher a combinação ideal de número de épocas, tamanho do lote e taxa de aprendizado para o modelo.

Para ilustrar o desempenho das diferentes combinações de hiperparâmetros, um gráfico de calor foi gerado.


- Número de épocas: 15.
- Tamanho do lote: 16.
- Taxa de aprendizado: 0.001.



Proposta: desenvolvimento do trabalho

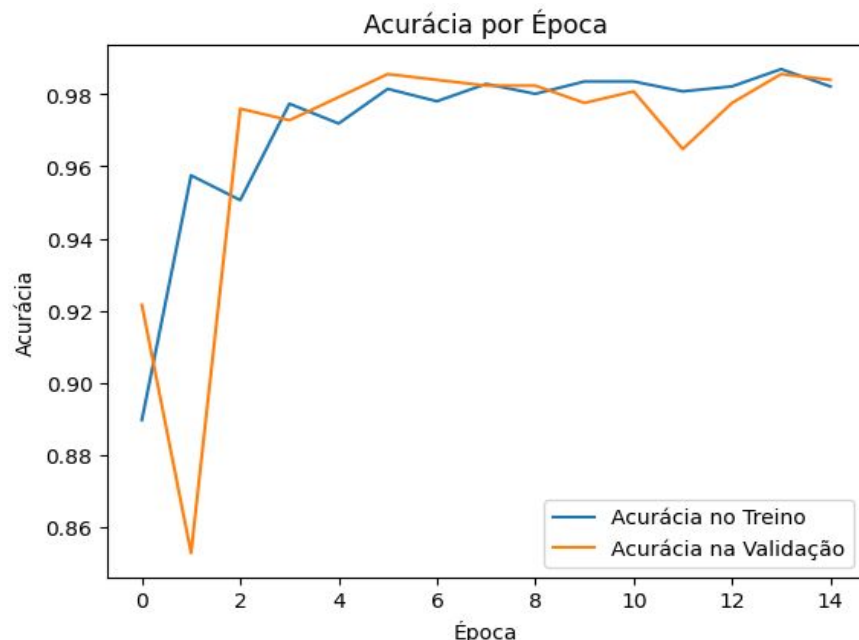
Arquitetura do modelo:

- O modelo utilizado é uma CNN, uma arquitetura profunda amplamente empregada em tarefas de processamento de imagens.
- A arquitetura da CNN foi projetada especificamente para extrair características relevantes de imagens radiográficas do tórax.
- **Camadas convolucionais:** Aplicam filtros às imagens de entrada para detectar padrões e características específicas. Utilizam funções de ativação ReLU para introduzir não linearidade.
- **Camadas de pooling:** Seguem as camadas convolucionais e reduzem a dimensionalidade da saída das camadas anteriores, preservando as características mais importantes.
- **Camadas densas:** A saída das camadas de pooling é achatada para criar um vetor unidimensional que serve como entrada para essas camadas. Elas realizam a classificação final com base nas características extraídas das camadas anteriores.
- **Camada de saída:** Utiliza uma função de ativação sigmoide, adequada para problemas de classificação binária, e fornece a probabilidade de pertencimento a uma das classes ("Covid" ou "Normal").




Proposta: desenvolvimento do trabalho

A divisão da base de dados para treinamento e teste foi feita na proporção de 80% para treinamento e 20% para teste.



Ilustra o gráfico da acurácia do modelo ao longo das épocas no conjunto de treinamento (linha azul) e no conjunto de teste (linha laranja).

As duas curvas estão subindo e mantendo-se próximas uma da outra, o que indica que o modelo está aprendendo bem e generalizando para novos dados.




O gráfico de perda exhibe como a perda do modelo se comportou durante o treinamento.

É possível notar ambas as curvas de treinamento e teste estão diminuindo, o que significa que o modelo está ajustando seus pesos para minimizar a perda e, portanto, fazendo previsões mais precisas.



Resultados




- A matriz de confusão revela que o modelo acertou 132 diagnósticos de Covid e 472 de Normal; errou ao prever 20 casos de Covid e um de Normal.

	precision	recall	f1-score	support
0	0.99	0.87	0.93	152
1	0.96	1.00	0.98	473
accuracy			0.97	625
macro avg	0.98	0.93	0.95	625
weighted avg	0.97	0.97	0.97	625

O relatório de classificação apresenta métricas como precisão, recall, f1-score e support.

- Precisão:** Indica a habilidade do classificador em não rotular como positiva uma amostra negativa.
- Recall:** Representa a habilidade do modelo em identificar todas as amostras positivas.
- F1-score:** Média harmônica ponderada entre precisão e recall.
- Support:** Número de ocorrências de cada classe no conjunto real.



- A métrica AUC-ROC foi aplicada para medir a capacidade do modelo em distinguir as classes e alcançou o valor de 0.9759, aproximando-se bastante de 1, evidenciando a excelente capacidade discriminativa do modelo.
- A posição da curva em relação à diagonal no gráfico ROC indica que o modelo tem uma alta taxa de verdadeiros positivos e uma baixa taxa de falsos positivos.



Resultados

Tabela 3 – Comparação de Resultados com Trabalhos Correlatos

Trabalho	Acurácia (%)
Este Estudo	98.40
(RESHI <i>et al.</i> , 2021)	100.00
(OHATA <i>et al.</i> , 2020)	95.00
(BARBOSA; COELHO; BAFFA, 2021)	99.36
(CHRISTOFOLLETTI; ATTUX, 2022)	90.26
ResNetX50 (SILVA <i>et al.</i> , 2020)	99.33
InceptionResNetV2 (SILVA <i>et al.</i> , 2020)	98.00

- O modelo deste estudo demonstrou uma alta acurácia de 98.4% na detecção de COVID-19 em imagens de raio-x do tórax.
- Ao comparar esses resultados com os trabalhos correlatos, observamos que nosso modelo se aproxima do desempenho alcançado pelo primeiro estudo com 100.0% de acurácia e supera o segundo estudo que obteve 95.0% de acurácia.



Conclusão e trabalhos futuros

- A implementação da CNN, conforme detalhado no código, revelou-se robusta.
- Este trabalho ressalta a viabilidade e eficácia de se usar CNNs na análise de imagens para detecção da Covid-19. Atingir acurácias tão altas em um cenário real tem implicações potenciais para aplicações clínicas, onde a detecção rápida e precisa pode fazer uma diferença significativa no tratamento e isolamento dos pacientes.
- Expandir a base de dados para aumentar a precisão e resiliência do modelo.
- Exploração de arquiteturas de redes mais complexas para melhorar ainda mais o desempenho.
- Incorporar técnicas adicionais de pré-processamento e aumento de dados.
- Investigação de abordagens de transferência de aprendizado, que podem ser proveitosas.

